.UBAECONÓMICAS

Métodos Predictivos para la gestión

Objetivo del Proyecto

Cada grupo deberá seleccionar un conjunto de datos (dataset) de su interés y aplicar el flujo completo de ciencia de datos: desde la curación y el análisis descriptivo hasta la implementación y comparación de modelos predictivos estadísticos y de Machine Learning.

i) Selección de Datos y Preprocesamiento (Unidad 2)

1. **Selección del Dataset:** Elegir una base de datos con un volumen suficiente de registros (mínimo 10.000 observaciones y no menos de 10 variables para analizar). La variable objetivo (target) puede ser numérica (para **Regresión**) o categórica (para **Clasificación**).
2. **Limpieza de Datos:**
    - Identificar y tratar valores faltantes (imputación o eliminación justificada).
    - Detectar valores atípicos (**outliers**) mediante métodos gráficos (Boxplots) o analíticos (Z-score).
    - Resolver inconsistencias lógicas y registros duplicados.
3. **Análisis Descriptivo:** Realizar un estudio analítico descriptivo (media, mediana, desvío, histogramas de distribución y matrices de correlación).

ii) Muestreo e Inferencia (Unidad 1)

1. **Extracción de la Muestra:** Sobre la base total, extraer una muestra aleatoria de $n = 750$ observaciones.
2. **Validación de la Muestra:** Justificar por qué la muestra es representativa. Se sugiere comparar la media y la varianza de la variable objetivo entre la muestra y la población original.

iii) Modelado Estadístico Clásico (Unidades 3, 4 y 5)

Dependiendo de la naturaleza de la variable objetivo, realizar el siguiente análisis:

- **Opción A (Regresión):** Si la variable es continua, ajustar un modelo de **Regresión Lineal**.
- **Opción B (Clasificación):** Si la variable es categórica, ajustar un modelo de **Regresión Logística**.

Tareas a realizar:

1. Ejecutar el modelo utilizando únicamente la **muestra de 750 registros**.
2. Repetir el análisis utilizando la **base de datos total**.
3. **Comparación Crítica:** Evaluar las diferencias en los coeficientes estimados, los errores estándar y la bondad de ajuste (R^2 o Accuracy según corresponda). Discutir cómo el tamaño de la muestra afectó la significatividad de los regresores.

iv) Machine Learning y Validación (Unidad 6)

Aplicar técnicas de aprendizaje supervisado sobre la base total:

1. **División de Datos:** Separar el dataset en conjuntos de Entrenamiento (**Train**) y Prueba (**Test**).
2. **Implementación de Algoritmos:** Entrenar al menos dos algoritmos vistos en clase (ej. Árboles de Decisión, Random Forest, k-NN o Gradient Boosting).
3. **Evaluación de Métricas:**
   - Para Regresión: MAE, MSE, RMSE y R^2.
   - Para Clasificación: Matriz de Confusión, Precisión, Recuperación, F1-Score y curva ROC-AUC.
4. **Optimización:** Mencionar brevemente si existió sobreajuste (**overfitting**) y cómo se controló (validación cruzada o ajuste de hiperparámetros).

v) Conclusión Comparativa

El informe final debe cerrar con una comparación entre:

- Los resultados del **modelo estadístico clásico** (enfocado en la interpretación de parámetros).
- Los resultados del **modelo de Machine Learning** (enfocado en la capacidad predictiva).
- Discusión sobre cuál modelo elegirían para un entorno de producción y por qué.

Metodología de Evaluación y Entrega

La evaluación del Trabajo Práctico Integrador se basará en dos instancias complementarias: la entrega de un documento técnico interactivo y una defensa oral.

1. Soporte Técnico: Google Colab

El trabajo deberá entregarse exclusivamente en formato Notebook de Google Colab. Se evaluará que el archivo sea "autosuficiente", cumpliendo con los siguientes requisitos:

- Reproducibilidad: El código debe poder ejecutarse de principio a fin sin errores, cargando las librerías necesarias y el dataset de forma correcta.
- Narrativa de Datos: No se trata solo de un script; se deben alternar celdas de código con celdas de texto que expliquen el procedimiento, justifiquen las decisiones tomadas y redacten las conclusiones.
- Regla de Interpretación Visual: Todo gráfico o tabla resumen debe estar acompañado por una celda de texto inmediatamente posterior. En ella, el grupo deberá realizar el análisis crítico de lo observado (ej. tendencias, sesgos, correlaciones o hallazgos relevantes).

2. Exposición Oral

Cada grupo realizará una exposición técnica en una fecha a designar. Los puntos clave a evaluar son:

- Capacidad de Síntesis: No se debe leer el código, sino exponer los puntos más relevantes de la investigación y los hallazgos del modelo.
- Dominio del Tema: Respuesta a preguntas técnicas sobre la metodología aplicada (preprocesamiento, muestreo y comparación de modelos).
- Comunicación Profesional: Claridad en el lenguaje y manejo del tiempo.

Nota importante: La calificación final es de carácter individual. Si bien parte de una base grupal obtenida por el trabajo entregado, el desempeño, la solvencia y la participación de cada alumno durante la exposición oral determinarán su nota definitiva.

Preguntas a responder Obligatorias

1. Exploración de la Identidad y el Contexto

Antes de mirar los datos, hay que entender de dónde vienen.

- **¿Cuál es la fuente de los datos?** ¿Es una base gubernamental, un registro de una empresa, una simulación o una encuesta?
- **¿Qué representa cada fila (observación)?** ¿Es un cliente, un día de ventas, un paciente, un sensor de una máquina?
- **¿En qué período de tiempo se recolectaron?** ¿Son datos actuales o históricos? ¿Podría haber factores externos (como una pandemia o crisis económica) que puedan haber sesgado este período?

2. Inventario y Tipología de Variables

- **¿Cuántas variables (columnas) tienen y de qué tipo son?** Clasifíquenlas en cualitativas (nominales/ordinales) y cuantitativas (discretas/continuas). Esto podrían resolverlo rápidamente con consultas en Python.
- **¿Cuál es la variable "Target" (objetivo)?** * Si es numérica (ej: precio, temperatura): ¿El enfoque será una **regresión**? Si es categórica (ej: abandonó/no abandonó, tipo de riesgo): ¿El enfoque será una **clasificación**?
- **¿Qué rango tienen las variables numéricas?** ¿Están en escalas muy diferentes (ej: edad 0-100 vs. salario 0-5.000.000)? *Esto les indicará si necesitan estandarizar o normalizar en la Unidad 2.*

3. Identificación de "Ruido" y Variables No Informativas

No todo lo que está en el dataset sirve para predecir.

- **¿Existen variables de identificación única?** (IDs, Nombres, Números de DNI). ¿Tienen algún poder predictivo o deben ser eliminadas de entrada?
- **¿Hay variables con varianza cero?** (Ej: una columna donde todos los registros dicen "Argentina"). ¿Aporta algo al modelo si no hay variabilidad?
- **¿Existen variables redundantes?** ¿Hay dos columnas que digan lo mismo en distinto formato (ej: "Fecha de nacimiento" y "Edad")? ¿Cuál conviene conservar?
- **¿Qué porcentaje de datos faltantes (NaN) tiene cada columna?** Si una columna tiene el 90% de datos vacíos, ¿vale la pena intentar completarla o es mejor descartarla?

4. Definición del Problema y Encuadre del Enfoque

Transformar los datos en una pregunta de negocio o investigación.

- **¿Qué pregunta intentan responder con estos datos?** (Ej: "¿Podemos predecir si un alumno aprobará basándonos en sus horas de estudio?" o "¿Cuánto costará una propiedad según sus metros cuadrados?").
- **¿Cuál es el "dolor" o la necesidad que resuelve su modelo?** ¿Quién usaría esta información y para qué tomaría una decisión basada en ella?
- **¿Cuál es su hipótesis inicial?** ¿Qué variables creen, *a priori*, que serán las más importantes para explicar el fenómeno? (Luego compararán esta intuición con el gráfico de importancia de variables de Machine Learning).

Las preguntas que siguen no son un cuestionario obligatorio. Son disparadores diseñados para ayudarlos a profundizar el análisis. Usarlas como guía para redactar sus celdas de texto y para organizar la defensa oral del proyecto.

I. El Momento de la Verdad: Exploración y Limpieza

- **Historia y Calidad:** ¿Qué historia cuentan estos datos antes de ser procesados? ¿Detectaron "ruidos" (IDs, constantes o errores de carga) que podrían ensuciar el análisis?
- **Tratamiento de Datos:** Al encontrar valores faltantes, ¿existe un patrón o son aleatorios? ¿Cómo cambia la distribución de sus variables si deciden eliminar esas filas en lugar de imputarlas?
- **El impacto de lo Atípico:** Los *outliers* detectados, ¿son casos excepcionales reales o errores de medición? Si deciden dejarlos, ¿cómo creen que afectarán la pendiente de sus modelos?
- **Relaciones:** Observando la matriz de correlación, ¿qué variables parecen "moverse juntas"? ¿Hay mucha colinealidad (variables que dicen lo mismo)?

II. El Desafío del Muestreo (n = 750)

¿Qué pasa cuando trabajamos con una parte en lugar del todo? (Inferencia).

- **Representatividad:** ¿Qué método de muestreo garantiza que la estructura de la población se mantenga? Si tienen categorías muy pequeñas pero importantes, ¿usaron un muestreo estratificado?
- Al comparar la muestra de 750 con la base total, ¿los promedios y proporciones se mantienen similares? ¿Qué creen que pasaría con sus conclusiones si la muestra fuera de solo 50 casos?
- **Estabilidad:** ¿Los coeficientes (β) obtenidos en la muestra son similares a los de la base completa? Si cambiaron drásticamente, ¿a qué fenómeno estadístico lo atribuyen?

III. El Duelo de Modelos: Estadística vs. Machine Learning

Interpretación frente a poder predictivo.

- ¿Es el modelo estadístico coherente con la realidad? Más allá del número, ¿qué significa el coeficiente de la variable X? (Ej: *"Por cada unidad que sube A, la variable objetivo varía en B"*).
- **Significatividad:** ¿Hubo variables que eran importantes (p-valor < 0.05) en la base total pero dejaron de serlo en la muestra? ¿Cómo influyó el tamaño de los datos en esto?

- ¿Por qué dividimos en *Train* y *Test*? ¿Qué riesgo correrían si evaluaran su algoritmo de Machine Learning con la misma muestra que usaron para la estadística?
- ¿Gana el Machine Learning en precisión o solo suma complejidad? Si el ML es solo un 2% mejor pero es más difícil de explicar, ¿cuál elegirían para una empresa?
- **Métricas de Error:** En su problema específico, ¿es más grave un Falso Positivo o un Falso Negativo? ¿Qué métrica (Precisión, Recall o F1) se adapta mejor al problema?

IV. La Mirada Crítica y Conclusiones

- ¿Qué fue lo que más les sorprendió al comparar la muestra pequeña con la base total? ¿Se rompió alguna intuición que tenían al principio?
- Si tuvieran que tomar una decisión de inversión o una política pública basada en este trabajo, ¿confiarían en sus resultados? ¿Por qué?
- ¿Qué datos no están en la base pero serían fundamentales para que el modelo fuera realmente potente?
- Al final del camino, ¿qué sacrificaron al elegir un modelo sobre otro: interpretabilidad o precisión?